

# 线性代数与向量微积分

## 1. 向量与空间


### 1.1 什么是向量

向量：具有大小和方向的量

向量  $\vec{a}$

$|\vec{a}|$  向量的模

### 1.2 向量运算



$$+ : \vec{a} + \vec{b} = \vec{c}$$

$$- : \vec{c} - \vec{a} = \vec{b}$$

$$\times : |\vec{a}| |\vec{c}| \cdot \cos \theta$$

=：方向相同，模相等

向量没有除法。为什么没有除法？

### 1.3 内积/范数/夹角

范数：

$$\|\mathbf{x}\| = \sqrt{x_1^2 + x_2^2 + \cdots + x_n^2} \quad (\text{Norm2})$$

$$\|\mathbf{x}\| + \|\mathbf{y}\| \geq \|\mathbf{x} + \mathbf{y}\| \quad \text{三角不等式}$$

$$\|\mathbf{x}\| = 1 \text{ 单位向量}$$

$$\|\mathbf{x}\|_1 = |\mathbf{x}_1| + |\mathbf{x}_2| + \cdots + |\mathbf{x}_n|$$

$$\|\mathbf{x}\|_\infty = \max |x_i|$$

$$\|\mathbf{x}\|_p = (|x_1|^p + |x_2|^p + \cdots + |x_n|^p)^{\frac{1}{p}} \quad (1 \leq p \leq n)$$

夹角：

$$\theta = \arccos \frac{[\vec{x}, \vec{y}]}{\|\vec{x}\| \|\vec{y}\|}$$

正交向量:  $[\vec{x}, \vec{y}] = 0$ , 则  $\vec{x}, \vec{y}$  正交,  $\vec{0}$  与任何向量都正交

正交向量组: 两两正交的向量组。

内积:

$$\vec{x} \cdot \vec{y} = \sum_{i=1}^n x_i y_i$$

$$\text{运算: } [\vec{x}, \vec{y}] = [\vec{y}, \vec{x}] \quad \vec{x} \cdot \vec{y} = |\vec{x}| \cdot |\vec{y}| \cdot \cos \theta$$

$$[\lambda \vec{x}, \vec{y}] = \lambda [\vec{x}, \vec{y}]$$

$$[\vec{x} + \vec{y}, \vec{z}] = [\vec{x}, \vec{z}] + [\vec{y}, \vec{z}]$$

定理:  $[\vec{x}, \vec{x}] \geq 0$ ; 当且仅当  $\vec{x} \neq \vec{0}$ ,  $[\vec{x}, \vec{x}] > 0$ ;

$$[\vec{x}, \vec{y}]^2 \leq [\vec{x}, \vec{x}] [\vec{y}, \vec{y}]$$

## 2. 从向量空间到矩阵

### 2.1 向量组, 向量空间

$\vec{a}, \vec{b}, \vec{c}, \vec{d}$

向量:  $\vec{a}_1, \vec{a}_2, \dots, \vec{a}_n$

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{bmatrix} \quad \text{—行向量组 | 列向量组}$$

①线性组合:  $\vec{a}_1, \vec{a}_2, \vec{a}_3, \dots, \vec{a}_m$  对于任意的实数  $k_1, k_2, \dots, k_m$ , 向量  $k_1 \vec{a}_1 + k_2 \vec{a}_2 + \dots + k_m \vec{a}_m$  称为向量组的一个线性组合。

②线性表示:  $\vec{b}$ , 存在  $k_1, k_2, \dots, k_m$ , 使  $\vec{b} = \sum_{i=1}^m k_i \vec{a}_i$ ,  $\vec{b}$  能被 A 线性表示。

③线性相关: 存在不全为零的数  $k_1, k_2, \dots, k_m$ , 使得  $\sum_{i=1}^m k_i \vec{a}_i = \vec{0}$ , 称 A 线性相关, 否

则线性无关。即当且仅当  $k_i$  全为 0 时,  $\sum_{i=1}^m k_i \vec{a}_i = \vec{0}$  成立。

## 2.2 向量空间与基

**定义 1:**  $V$  为  $n$  维向量的集合, 如果集合  $V$  非空, 且集合  $V$  对加法及数乘两种运算封闭, 那么称集合  $V$  为向量空间。

$$\textcircled{1} \vec{\alpha} \in V, \vec{\beta} \in V, (\vec{\alpha} + \vec{\beta}) \in V$$

$$\textcircled{2} \vec{\alpha} \in V, \lambda \vec{\alpha} \in V$$

**定义 2:**

子空间:  $V_1, V_2$  为向量空间, 若  $V_1 \in V_2$ , 则  $V_1$  是  $V_2$  的子空间。

**定义 3:**  $V$  是向量空间, 如果  $r$  个向量  $\vec{\alpha}_1, \vec{\alpha}_2, \dots, \vec{\alpha}_r \in V$

且  $\vec{\alpha}_1, \vec{\alpha}_2, \dots, \vec{\alpha}_r$  线性无关

$V$  中任一向量可由  $\vec{\alpha}_1, \vec{\alpha}_2, \dots, \vec{\alpha}_r$  线性表示

那么称  $\vec{\alpha}_1, \vec{\alpha}_2, \dots, \vec{\alpha}_r$  为  $V$  的一组基,  $r$  称为向量空间  $V$  的维数, 即  $r$  维向量空间。

## 2.3 欧氏空间

$V$  是实数域上的线性空间, 对于  $V$  中任意两个向量  $\alpha, \beta$ , 定义一个二元实函数, 记为  $(\alpha, \beta)$ , 满足若  $(\alpha, \beta), \forall \alpha, \beta, \gamma \in V, \forall k \in R$ ,

$$\textcircled{1} (\alpha, \beta) = (\beta, \alpha) \text{ 对称性}$$

$$\textcircled{2} (k\alpha, \beta) = k(\alpha, \beta) \text{ 数乘}$$

$$\textcircled{3} (\alpha + \beta, \gamma) = (\alpha, \gamma) + (\beta, \gamma) \text{ 可加性}$$

$$\textcircled{4} (\alpha, \alpha) \geq 0. \text{ 当且仅当 } \alpha = 0, (\alpha, \alpha) = 0 \text{ 正交性}$$

称  $(\alpha, \beta)$  为内积运算, 并称定义了这种内积的实数域  $R$  上的线性空间  $V$  为欧氏空间。

## 3. 矩阵

### 3.1 矩阵的运算 (+, -, ×, 数乘)

det. T. -1. 矩阵的相似, 特征值, 特征向量

1、 $A+B$   $A \times B$  (不满足交换律)

$$A - b \quad A^T \quad (AB)^T = B^T A^T \text{ (转置)}$$


$$A^{-1} B = A \setminus B \text{ (左除)}$$

$$\mathbf{A}\mathbf{B}^{-1}=\mathbf{A}/\mathbf{B} \text{ (右除)}$$

2、逆矩阵（方阵才有逆矩阵）。

$\mathbf{A} \cdot \mathbf{A}^{-1} = \mathbf{I}$ （则  $\mathbf{A}$  为满秩），则称  $\mathbf{A}^{-1}$  为  $\mathbf{A}$  的逆矩阵。

3、 $\det \mathbf{A}$  的物理意义：



$$\begin{bmatrix} a_1 & b_1 \\ a_2 & b_2 \end{bmatrix} \quad \begin{vmatrix} a_1 & b_1 \\ a_2 & b_2 \end{vmatrix}$$

$$\begin{aligned} S_{OACB} &= S_{OEDB} + S_{CDB} - S_{AED} - S_{AEDC} \\ &= a_1 b_2 - a_2 b_1 \end{aligned}$$

### 3.2 矩阵的秩

最大线性无关组（向量组） $\mathbf{A}$ :  $\vec{\alpha}_i, i=1, 2, \dots, m$ ，如果， $\exists r$ ，满足

①  $\vec{\alpha}_i, i=1, 2, \dots, r$ ，线性无关

②任意  $r+1$  个向量都线性相关

则称向量组  $\vec{\alpha}_1 \cdots \vec{\alpha}_r$  是向量组  $\mathbf{A}$  的一个最大线性无关组，包含的向量个数称为向量组  $\mathbf{A}$  的秩，记为  $R_{\mathbf{A}}$

矩阵的秩等于行向量组的秩，也等于列向量组的秩。

### 3.3 特征值（向量）

定义：设  $\mathbf{A}$  是  $n$  阶矩阵，若存在数  $\lambda$  和非零向量  $\vec{x}$ ，使  $\mathbf{A}\vec{x} = \lambda\vec{x}$ ，成立，则称数  $\lambda$  为  $\mathbf{A}$  的特征值。并称  $\vec{x}$  为矩阵  $\mathbf{A}$  的属于特征值  $\lambda$  的特征向量。

特征向量的物理意义：如果将矩阵  $\mathbf{A}$  视为一个线性变换，线性变换作用在向量  $\vec{x}$  上相当于对向量  $\vec{x}$  进行了线性拉伸。

特征向量的应用：PCA 中主成分方向就是协方差矩阵的特征向量的方向。参考《Eigenproblems in Pattern Recognition》。

### 3.4 相似矩阵

定义：设  $\mathbf{A}$ 、 $\mathbf{B}$  是  $n$  阶方阵，若存在  $n$  阶可逆矩阵  $\mathbf{P}$ ，使得  $\mathbf{P}^{-1}\mathbf{A}\mathbf{P}=\mathbf{B}$ ，则称  $\mathbf{A}$  与  $\mathbf{B}$  相似， $\mathbf{B}$  称为  $\mathbf{A}$  相似矩阵。

例： $\mathbf{A}$  有  $n$  个特征向量  $\mathbf{P}_1, \mathbf{P}_2, \dots, \mathbf{P}_n$ 。则  $\mathbf{A}\mathbf{P}=\mathbf{P}\mathbf{\Lambda}$

$$\text{取 } \Lambda = \begin{bmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

$\therefore \mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \Lambda$ ， $\mathbf{A}$  与  $\Lambda$  相似

### 3.5 矩阵逆的物理意义

基变换与坐标变换， $\mathbb{R}^3$  为例

1)  $\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3$  为一组基， $\mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3$  为一组新基

$$(\mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3) = (\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3) \mathbf{P}, \quad \mathbf{P} = \mathbf{A}^{-1}\mathbf{B} \quad (\text{旧基到新基})$$

2) 坐标变换

旧基为  $(y_1, y_2, y_3)$  新基为  $(z_1, z_2, z_3)$ ，则

$$\begin{array}{c} \mathbf{X} = \mathbf{A} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \mathbf{B} \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix} \Rightarrow \begin{bmatrix} z_1 \\ z_2 \\ z_3 \end{bmatrix} = \mathbf{B}^{-1}\mathbf{A} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} \\ \downarrow \qquad \qquad \qquad \downarrow \\ [\mathbf{a}_1, \mathbf{a}_2, \mathbf{a}_3] \qquad \qquad \mathbf{P}^{-1} \end{array}$$

### 3.6 线性方程组的物理意义

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1, 0 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = b_m, 0 \end{cases} \Rightarrow \mathbf{Ax} = \mathbf{b} / \mathbf{0}$$

$\downarrow$   
 $\sum_{i=1}^n x_i \vec{a}_i = \vec{b}$

$\downarrow$   
 $\begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{m1} & \dots & a_{mn} \end{bmatrix}$

$\downarrow$   
 $\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$

$\mathbf{Ax} = \vec{0}$  齐次  
 $\mathbf{Ax} = \mathbf{b}$  非齐次

方程组

$\mathbf{Ax} = \vec{0}$  的解空间  $R_s = n - r$

$R(\mathbf{A}) = r < n$  方程组有一个含  $n - r$  个向量的基础解系  $S_1, S_2, \dots, S_{n-r}$

$x = \sum_{k_i} k_i s_i$  为方程组的解。

引申：子空间方法的物理意义

## 4. 向量微积分

### 4.1 Jacobian 矩阵

$\mathbf{y} = \varphi(\mathbf{x})$   $\mathbf{y}$  是  $m \times 1$  维矩阵  $\mathbf{x}$  是  $n \times 1$  维矩阵

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \vdots & & \vdots \\ \frac{\partial y_m}{\partial x_1} & \frac{\partial y_m}{\partial x_2} & \dots & \frac{\partial y_m}{\partial x_n} \end{bmatrix}$$

$\because y_i = \sum_{k=1}^n w_{ik} \times x_k, \therefore \frac{\partial y_i}{\partial x_j} = w_{ij}$

即  $\mathbf{y} = \mathbf{W}\mathbf{x}$

$\downarrow$   
 $m \times 1$

$\downarrow$   
 $m \times n$

$\downarrow$   
 $n \times 1$

$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{W}^T$

$\downarrow$   
 $n \times m$

## 4.2 向量微积分常见形式

$$\mathbf{y} = \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \mathbf{Ax} & \mathbf{A}^T \\ \mathbf{x}^T \mathbf{A} & \mathbf{A} \\ \mathbf{x}^T \mathbf{x} & 2\mathbf{x} \\ \mathbf{x}^T \mathbf{Ax} & \mathbf{Ax} + \mathbf{A}^T \mathbf{x} \end{bmatrix}$$

$\mathbf{y} = \mathbf{x}^T \mathbf{Ax}$  如果  $\mathbf{A}$  是对称矩阵

$$\text{则 } \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = 2\mathbf{Ax}$$

形如  $\mathbf{x}^T \mathbf{Ax}$ ，可用复合函数求导证明

$$\text{求得 } \mathbf{y}' = \mathbf{Ax} + \mathbf{A}^T \mathbf{x}$$

## 4.3 应用：ridge regression 岭回归

$$loss = \sum_{i=1}^n (\mathbf{y}_i - \mathbf{x}_i^T \boldsymbol{\beta})^2 + \lambda \sum_{j=1}^p \beta_j^2$$

$$\boldsymbol{\beta} = \arg \min \|\mathbf{y} - \mathbf{x}\boldsymbol{\beta}\|_2^2 + \lambda \|\boldsymbol{\beta}\|_2^2 \quad (\boldsymbol{\beta} \in \mathbf{R}^p, \mathbf{x} \in \mathbf{R}^{n \times p}, \mathbf{y} \in \mathbf{R}^n)$$

$$L = (\mathbf{y} - \mathbf{x}\boldsymbol{\beta})^T (\mathbf{y} - \mathbf{x}\boldsymbol{\beta}) + \lambda \|\boldsymbol{\beta}\|_2^2$$

$$\frac{\partial L}{\partial \boldsymbol{\beta}} = \mathbf{0} \rightarrow -2\mathbf{x}^T (\mathbf{y} - \mathbf{x}\boldsymbol{\beta}) + 2\lambda \boldsymbol{\beta} = \mathbf{0}$$

半正定矩阵  $\mathbf{x}^T \mathbf{Ax} \geq 0$ ，则  $\mathbf{A}$  为半正定

$$(\mathbf{x}^T \mathbf{x} + \lambda) \boldsymbol{\beta} = \mathbf{x}^T \mathbf{y}$$

$$\boldsymbol{\beta} = (\mathbf{x}^T \mathbf{x} + \lambda)^{-1} \mathbf{x}^T \mathbf{y}$$

$$\downarrow$$

$$\lambda \mathbf{I}$$

$$\text{求导过程: } \frac{\partial L}{\partial \boldsymbol{\beta}} = \mathbf{y}^T \mathbf{y} - \boldsymbol{\beta}^T \mathbf{x}^T \mathbf{y} + \boldsymbol{\beta}^T \mathbf{x}^T \mathbf{x} \boldsymbol{\beta} - \mathbf{x} \boldsymbol{\beta} \mathbf{y}^T + \lambda \boldsymbol{\beta}^T \boldsymbol{\beta}$$

$$\rightarrow -\mathbf{x}^T \mathbf{y} + 2\mathbf{x}^T \mathbf{x} \boldsymbol{\beta} - \mathbf{x}^T \mathbf{y} + 2\lambda \boldsymbol{\beta}$$

$$\rightarrow 2\mathbf{x}^T (\mathbf{y} - \mathbf{x}\boldsymbol{\beta}) + 2\lambda \boldsymbol{\beta}$$

## 线性代数习题

- 1、证明： $\mathbf{y} = \mathbf{w}^T \mathbf{x} + \mathbf{b}$  每条映射的权重， $\mathbf{w}_{ij}$  还是  $\mathbf{w}_{ji}$ 。
- 2、说明向量运算为什么没有除法。
- 3、证明矩阵的秩等于行向量的秩，也等于列向量的秩。
- 4、多维  $\det$  的物理意义。
- 5、 $\begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & -\cos \theta \end{bmatrix}$  求特征值。
- 6、证明： $\mathbf{y} = \mathbf{x}^T \mathbf{A}$ ， $\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \mathbf{A}$ 。